

Đo lường và Cải thiện Tính Giống-Người của Lời giải CFOP do AI Sinh ra cho Rubik’s Cube: Phương pháp Trigger-Biased Search

Phạm Đăng Khuê
Khoa Công nghệ thông tin, Trường Đại học Điện lực
pdkhue2004@gmail.com

Abstract

Các phương pháp tính toán hiện có để giải Rubik’s Cube — bao gồm tìm kiếm bằng pattern-database [4], các solver tối ưu dựa trên lý thuyết nhóm [7, 3], và học tăng cường [6] — hầu như chỉ tối ưu hóa số nước đi, tạo ra các lời giải đúng nhưng phần lớn không thể diễn giải được đối với người học. Ngược lại, phương pháp CFOP do con người thiết kế (Cross, F2L, OLL, PLL) đánh đổi tính tối ưu về số nước để lấy *khả năng học được*, được cấu trúc quanh một tập hữu hạn các pattern chuỗi-nước đi dễ nhớ (“thuật toán”). Chúng tôi hình thức hóa khái niệm *tính giống người* của một kế hoạch giải cube bằng ngôn ngữ của lập kế hoạch AI nhận biết con người (human-aware AI planning) [5, 1], đề xuất một *Chỉ số Giống-Người* (Human-Likeness Index — HLI) tổng hợp từ ba thành phần đo lường được (khả năng phân đoạn giai đoạn, độ khớp mẫu-thuật-toán-có-tên, và độ trùng lặp finger-trick), và giới thiệu *Trigger-Biased A* Search*, một cải tiến heuristic-search thường rõ ràng cho các nhánh tìm kiếm trùng khớp với kho finger-trick của con người. Các thí nghiệm thực nghiệm ($N=60$ scramble random-state cho so sánh cơ sở, kiểm tra độ mạnh mẽ trên $N=100$ scramble random-move, $N=60$ cho quét Pareto) cho thấy việc thiên vị heuristic tìm kiếm F2L làm tăng độ trùng lặp trigger từ mức cơ sở 9,0% lên 25,5% tại $\lambda = 1,0$ (Wilcoxon $p = 8,3 \times 10^{-8}$), với chi phí chỉ 7,4% số nước tăng thêm (Wilcoxon $p = 0,0014$), cho thấy một sự đánh đổi Pareto thuận lợi (dù phi tuyến về thời gian tính toán). Một nghiên cứu giám khảo con người mù, kiểu BotPrize [2] (24 mẫu, 28 người chấm) xác nhận construct validity của HLI (Spearman $\rho = 0,487$, $p = 0,016$ so với điểm đánh giá giống-người trung bình) và cho thấy Trigger-Biased Search đưa các lời giải do AI sinh ra từ trạng thái *phân biệt được về mặt thống kê* với người thật ($p = 0,005$) sang *không phân biệt được về mặt thống kê* với người thật ($p = 0,109$) trong đánh giá mù. Theo hiểu

biết của chúng tôi, đây là nghiên cứu đầu tiên áp dụng các chỉ số kiểu explicability vào một miền tìm kiếm tổ hợp quy mô lớn, kết nối AI tìm kiếm heuristic cổ điển với nghiên cứu AI nhận biết con người và AI tác nhân đáng tin (believable-agent AI).

1 Giới thiệu

Giải Rubik's Cube từ lâu đã là một miền benchmark cho tìm kiếm heuristic và tối ưu hóa tổ hợp [4, 7], và gần đây hơn là cho học tăng cường tự chơi (self-play reinforcement learning) [6]. Các phương pháp này có chung một mục tiêu: tối thiểu hóa số nước đi (hoặc tối đa hóa tỷ lệ thắng trước một bộ sinh scramble đối kháng), không quan tâm liệu lời giải thu được có tương ứng với bất kỳ pattern nào mà con người có thể học, ghi nhớ, hoặc giải thích hay không.

Ngược lại, các speedcuber con người sử dụng các phương pháp có cấu trúc như CFOP (Cross, F2L, OLL, PLL), chủ động đánh đổi tính tối ưu về số nước đi lấy *khả năng học được*: mỗi giai đoạn được rút gọn thành việc nhận diện một trong số hữu hạn các "case" chuẩn, mỗi case đi kèm một thuật toán cố định, có tên. Phương pháp CFOP đầy đủ gồm 57 case OLL có tên và 21 case PLL có tên; một biến thể rút gọn được dùng rộng rãi ("2-look OLL/PLL") giải mỗi giai đoạn qua hai lượt tuân tự dùng một tập con nhỏ hơn nhiều các thuật toán, với cái giá là tốn thêm nước đi. Hệ thống của chúng tôi cài đặt một bảng đã kiểm chứng đầy đủ 21 case PLL (Mục 4.1) nhưng chỉ có OLL 2-look (2 thuật toán sinh, Sune/Anti-Sune, thay vì đầy đủ 57 case); sự bất đối xứng này tự nó có giá trị thông tin cho việc đo lường Pattern-conformity (Mục 4).

Ba hướng nghiên cứu liên quan (Mục 2) hiện chưa giao nhau: các solver Rubik's Cube tối-ưu-kiểu-máy-tính (Mục 2.1) không quan tâm đến khả năng diễn giải; lập kế hoạch AI nhận biết con người (Mục 2.2) đã hình thức hóa explicability nhưng mới chỉ áp dụng cho các bài toán lập kế hoạch tác vụ ký hiệu quy mô nhỏ, chưa cho một miền tìm kiếm tổ hợp quy mô lớn như Rubik's Cube; cộng đồng AI game (Mục 2.3) đã phát triển phương pháp luận đánh giá tính giống-người bằng giám khảo con người mù (BotPrize) nhưng chưa từng áp dụng cho một tác nhân giải câu đố tổ hợp. Hệ thống dạy học CFOP gần nhất (ALLURE, Mục 2.4) chỉ bao phủ mục tiêu con Cross và không báo cáo một đánh giá giống-người mù có thể so sánh được. Bài báo này lấp khoảng trống đó bằng cách kết hợp cả ba hướng: một chỉ số giống-người hình thức hóa theo ngôn ngữ explicability, một cơ chế tìm kiếm tối ưu hóa rõ ràng cho chỉ số đó, và một nghiên cứu giám khảo con người mù để kiểm chứng cả hai.

Đóng góp. Bài báo này có các đóng góp sau:

1. Một hình thức hóa *tính giống người* cho các kế hoạch giải cube, dựa trên khái niệm explicability của lập kế hoạch nhận biết con người [5, 1], cụ thể hóa thành **Chỉ số Giống-Người (HLI)** tổng hợp với ba thành phần đo lường được, tái lập được (Mục 4).
2. **Trigger-Biased A* Search**: một cải tiến tối giản, tương thích ngược đối với A* search dẫn dắt bởi pattern-database cho F2L, tối ưu hóa rõ ràng cho độ trùng lặp finger-trick con người thông qua một siêu tham số λ duy nhất, dễ diễn giải (Mục 4).
3. Một phân tích Pareto thực nghiệm về sự đánh đổi giữa tính giống-người / số nước đi / thời gian tính toán do λ gây ra (Mục 6).
4. Một nghiên cứu giám khảo con người mù, kiểu BotPrize [2] (24 mẫu, 28 người chấm) vừa construct-validate HLI đối chiếu với đánh giá con người, vừa cho thấy Trigger-Biased Search thu hẹp khoảng cách giống-người xuống mức không phân biệt được về thống kê so với lời giải người thật (Mục 6.3).

2 Công trình liên quan

2.1 Các solver Rubik's Cube tối ưu kiểu máy tính

IDA* của Korf kết hợp pattern database cộng dồn [4] là phương pháp đầu tiên tìm được lời giải tối ưu chứng minh được cho scramble bất kỳ. Rokicki và cộng sự [7] đã chứng minh mọi trạng thái cube đều giải được trong tối đa 20 nước xoay mặt ("God's Number"), thông qua tìm kiếm dựa trên coset quy mô lớn. Thuật toán hai pha của Kociemba [3] đánh đổi tính tối ưu tuyệt đối để lấy thời gian chạy khả thi, thường trả về lời giải chỉ cách tối ưu 1-4 nước, và là baseline chúng tôi dùng trong Mục 5. McAleer và cộng sự [6] cho thấy một tác nhân học tăng cường (DeepCubeA) có thể học giải cube mà không cần tri thức con người có sẵn, đạt độ dài lời giải gần tối ưu. Không phương pháp nào trong số này tạo ra kế hoạch có thể phân đoạn, có tên, hay diễn giải được theo cách con người học có thể nhận ra — chúng, theo thuật ngữ của chúng tôi, mang tính *computer-like* tối đa.

2.2 Lập kế hoạch nhận biết con người và explicability

Một hướng nghiên cứu riêng trong lập kế hoạch AI nghiên cứu cách các tác nhân tự động nên hành xử khi được quan sát hoặc hỗ trợ bởi con người có một mô hình tinh thần nội tại, có thể không hoàn hảo, về tác nhân đó. Kulkarni và cộng sự [5] hình thức hóa *explicability* là việc tối thiểu hóa khoảng cách giữa kế hoạch thực tế của tác nhân

và kế hoạch mà người quan sát kỳ vọng, và đề xuất các sửa đổi tìm kiếm thiên vị việc lập kế hoạch hướng tới các quỹ đạo để giải thích hơn — về cấu trúc tương tự heuristic thiên vị-trigger mà chúng tôi đề xuất trong Mục 4, nhưng áp dụng ở đây cho lập kế hoạch tác vụ ký hiệu thay vì một miền câu đố tổ hợp quy mô lớn. Chakraborti và cộng sự [1] khảo sát bối cảnh này (explicability, legibility, predictability, transparency), mà chúng tôi dùng làm từ vựng lý thuyết cho bài báo này. Zhang và cộng sự [11] đề xuất một cách tính explicability/predictability cụ thể cho lập kế hoạch tác vụ robot bằng cách học một hàm gán nhãn từ dữ liệu huấn luyện, khác với cách tiếp cận đo lường trực tiếp, không cần học, mà chúng tôi dùng cho các thành phần của HLI (Mục 4).

2.3 Tính giống người / độ tin cậy của tác nhân chơi game

Độc lập với hướng trên, cộng đồng AI game từ lâu đã nghiên cứu cách làm cho tác nhân tự động *trông giống* con người. Cuộc thi 2K BotPrize [2] đã hiện thực hóa điều này thành một biến thể Turing test, trong đó giám khảo con người chấm điểm cả người chơi thật lẫn bot trên thang 1-5 về mức độ giống người, mà không được biết ai là ai. Trong kỳ thi năm 2012, hai bot – UT² (Đại học Texas tại Austin) và MirrorBot (Mihai Polceanu) – lần đầu tiên vượt qua ngưỡng 50% về tỷ lệ được chấm là “người thật”, thậm chí còn cao hơn tỷ lệ chấm cho chính những người chơi thật tham gia kỳ thi năm đó, cho thấy một tác nhân tự động được tối ưu hóa rõ ràng cho việc “trông giống người” có thể vượt qua chính con người trên chính thước đo giống-người đó. Một khảo cứu gần đây [8] đóng khung nghiên cứu AI game giống-người quanh hai câu hỏi — làm sao mô hình hóa/cài đặt hành vi giống người, và làm sao đo mức độ giống người đó — mà chúng tôi dùng làm cấu trúc tổ chức cho hai đóng góp chính của bài báo này (Mục 4).

2.4 Hệ thống dạy học riêng cho CFOP

Gắn với công trình của chúng tôi nhất, hệ thống ALLURE [9] kết hợp một solver tự động (tìm kiếm dựa trên DeepCubeA qua các mục tiêu con) với một chatbot gia sư tương tác để giúp người học hiểu các lời giải có thể giải thích được cho mục tiêu con White Cross của CFOP; một nghiên cứu pilot gần đây [10] (bản thảo chưa công bố tại thời điểm viết bài) phân tích các pattern tương tác của học sinh trong ALLURE qua phân cụm hành vi, báo cáo rằng chiến lược white-cross cho người mới đòi hỏi nhiều nước đi hơn đáng kể so với CFOP, mà bản thân CFOP lại đòi hỏi nhiều nước hơn các phương pháp tối ưu hoàn toàn — minh họa trực tiếp sự đánh đổi khả-năng-học/tính-tối-ưu

là trọng tâm của hình thức hóa chúng tôi (Mục 3). Công trình của chúng tôi khác biệt ở (a) phạm vi — bao phủ cả bốn giai đoạn CFOP thay vì chỉ Cross — (b) cơ chế — một thiên vị tìm kiếm tường minh, điều chỉnh được (Mục 4) thay vì giải thích ngôn ngữ tự nhiên hậu-nghiệm cho các nước đi đã được tìm ra bởi một solver không ràng buộc — và (c) đánh giá — không nghiên cứu ALLURE nào báo cáo một đánh giá giống-người mù có thể so sánh với Experiment 3 của chúng tôi (Mục 6.3).

3 Hình thức hóa Bài toán

Gọi G là nhóm Rubik’s Cube ($|G| \approx 4,3 \times 10^{19}$), và gọi một *kế hoạch* $\pi = (m_1, \dots, m_k)$ là một chuỗi các phép sinh xoay-mặt giải một scramble $s \in G$ cho trước. Gọi M_H là một *mô hình kỳ vọng con người*: trong bài báo này, M_H được cụ thể hóa thành (i) sự phân rã giai đoạn CFOP (Cross $\rightarrow$ F2L $\rightarrow$ OLL $\rightarrow$ PLL), (ii) một bảng hữu hạn các thuật toán chuẩn, có tên cho OLL/PLL (Mục 4.1), và (iii) một kho T các n-gram nước-đi ngắn (“finger-trick”) thường được thực hiện như một đơn vị vận động duy nhất bởi người giải (Mục 4.1).

Theo Kulkarni et al. [5], chúng tôi định nghĩa tính giống người là một khoảng cách (nghịch đảo) giữa π và hành vi mà M_H coi là tự nhiên. Chúng tôi cụ thể hóa khoảng cách này thành tổng có trọng số của ba thành phần đã chuẩn hóa, đo lường được độc lập (thay vì một hàm khoảng cách học được hoặc điều chỉnh thủ công đơn lẻ), được mô tả trong Mục 4.

4 Phương pháp

4.1 Chỉ số Giống-Người (HLI)

Khả năng phân đoạn $S(\pi) \in [0, 1]$. Bằng 1 khi và chỉ khi π phân rã thành bốn đoạn con liên kế, kiểm chứng độc lập được, thỏa mãn lần lượt các hậu-điều-kiện Cross, F2L, OLL, và PLL theo đúng thứ tự, và bằng 0 trong trường hợp ngược lại (ví dụ với các kế hoạch giải cube bằng một chuỗi tối ưu không phân biệt được giai đoạn, như cách các solver kiểu máy tính làm theo cấu trúc của chúng).

Độ khớp mẫu $P(\pi) \in [0, 1]$. Giới hạn ở các giai đoạn OLL và PLL (nơi tồn tại một ánh xạ case-sang-thuật-toán hữu hạn, có tên trong CFOP), $P(\pi)$ là tỷ lệ các giai đoạn đã giải mà đoạn con nước-đi tương ứng khớp chính xác với một mục trong bảng đã kiểm chứng các thuật toán chuẩn (Aa, Ab, ..., Z cho PLL; các thuật toán sinh Sune/Anti-Sune cho OLL 2-look) thay vì rơi vào tìm kiếm không cấu trúc. Toàn bộ 21/21

case PLL trong bảng đã được kiểm chứng tự động khi module được import lần đầu, thông qua `verify_and_build_table()` (`solver/pll_algorithms.py`); chúng tôi xác nhận lại điều này bằng cách chạy trực tiếp hàm này, thu được đúng 21 tên case đã kiểm chứng (Aa, Ab, E, F, Ga, Gb, Gc, Gd, H, Ja, Jb, Na, Nb, Ra, Rb, T, Ua, Ub, V, Y, Z).

Độ trùng lặp Trigger $O(\pi) \in [0, 1]$. Đối với các giai đoạn Cross và F2L (vốn thiếu một bảng case chuẩn trong hệ thống này, được sinh ra bởi tìm kiếm heuristic không ràng buộc), chúng tôi đo tỷ lệ số nước đi được bao phủ bởi một phép phân đoạn greedy-longest-match của π đối chiếu với một kho hạt giống T gồm $|T| = 11$ finger-trick phổ biến của con người (ví dụ "sexy move" $RU R' U'$, "sledgehammer" $R' F R F'$; kho đầy đủ trong Phụ lục A). Đây là một kho hạt giống (seed corpus) được tuyển chọn thủ công từ tri thức phổ biến trong cộng đồng speedcubing, không suy ra từ thống kê n-gram trên log solve người thật; một bản mở rộng nên thay thế/bổ sung kho này bằng cách thống kê trực tiếp từ log solve thật (ví dụ file .log của CSTimer) để giảm thiên vị do tự chọn corpus.

HLI tổng hợp.

$$\text{HLI}(\pi) = w_S \cdot S(\pi) + w_P \cdot P(\pi) + w_O \cdot O(\pi), \quad w_S + w_P + w_O = 1$$

Chúng tôi dùng $(w_S, w_P, w_O) = (0, 3; 0, 4; 0, 3)$ trong bản thảo này. Chúng tôi đã thực hiện một phân tích độ nhạy hậu-nghiệm dùng $N = 78$ cặp scramble (Nhóm A so với Nhóm B, Experiment 1), đo cả ba thành phần HLI cho *cả hai* nhóm — bao gồm, quan trọng nhất, độ trùng lặp trigger của Nhóm B (đo trực tiếp trên chuỗi nước đi thực tế của Kociemba, không giả định bằng 0: trung bình $0,009 \pm 0,046$, xác nhận thực nghiệm rằng một bộ tối ưu hóa không có động lực hướng tới finger-trick con người về cơ bản không bao giờ tạo ra chúng một cách tình cờ). Trên toàn bộ các bộ trọng số đã thử (năm bộ đặt tên cộng với một lượt quét $w_S \in \{0; 0, 2; \dots; 1\}$), khoảng cách HLI giữa Nhóm A và Nhóm B vẫn lớn và dương chặt, dao động từ 0,397 (trọng số thiên-về-trigger) đến 1,000 (trọng số chỉ-có-segmentability), với bộ trọng số chúng tôi chọn cho khoảng cách 0,653. Điều này cho thấy tuyên bố trung tâm của bài báo — rằng AI-CFOP giống người hơn đáng kể so với baseline tối ưu-kiểu-máy-tính — là robust với lựa chọn cụ thể của (w_S, w_P, w_O) trong bất kỳ phạm vi hợp lý nào, dù *độ lớn* của khoảng cách tự nhiên phụ thuộc vào trọng số.

4.2 Trigger-Biased A* Search

Solver F2L của chúng tôi dùng A* với heuristic $h(n) = h_{\text{PDB}}(n) + \text{penalty}(n)$, trong đó h_{PDB} là một ước lượng pattern-database đơn-quân admissible và $\text{penalty}(n)$ không khuyến khích việc làm xáo trộn

các quân đã giải xong (Cross và các cặp F2L trước đó). Chúng tôi thêm một số hạng thứ ba:

$$f'(n) = g(n) + h_{\text{PDB}}(n) + \text{penalty}(n) - \lambda \cdot \text{bonus}(\text{path}(n))$$

trong đó $\text{bonus}(\text{path})$ là số nước đi trong đường đi hiện tại được bao phủ bởi một phép khớp greedy-longest-match đối chiếu với kho T (cùng quy trình khớp dùng để tính $O(\pi)$ tại thời điểm đánh giá, đảm bảo tính nhất quán giữa mục tiêu lúc tìm kiếm và chỉ số lúc đánh giá). $\lambda = 0$ khôi phục chính xác tìm kiếm gốc, không thiên vị (tương thích ngược hình thức: chúng tôi đã xác nhận cả 176 unit test có sẵn từ trước đều pass không đổi với $\lambda = 0$). Tăng λ đánh đổi tính tối ưu của tìm kiếm (và, như chúng tôi cho thấy thực nghiệm, thời gian tính toán) để lấy độ trùng lặp trigger.

5 Thiết lập Thực nghiệm

Baseline (kiểu máy tính). Thuật toán hai pha của Kociemba [3], thông qua gói Python công khai `kociemba`, chạy trên cùng scramble.

Sinh scramble. Kết quả chính dùng scramble random-move (20 nước, không lặp mặt liên tiếp) để nhất quán giữa Experiment 1-2. Chúng tôi cũng cài đặt thêm một bộ sinh scramble kiểu WCA *random-state* (random walk dài để xấp xỉ phân bố trạng thái đều, sau đó nghịch đảo một lời giải Kociemba gần-tối-ưu của trạng thái đó — đảm bảo scramble cần số nước gần với số nước tối ưu để hoàn tác, khớp với phương pháp sinh scramble thi đấu thật) và đã xác nhận kết quả nhất quán giữa hai bộ sinh (Mục 7).

Phần cứng / cài đặt. Sandbox đám mây đơn lõi (1 vCPU, 4GB RAM), Python 3.12, biểu diễn cube dựa trên NumPy. Mọi thí nghiệm dùng 1 seed gốc cố định cho mỗi điều kiện (`random.Random(seed)`, seed 5000-5059 cho Experiment 1 chính (random-state), 1000-1099 cho lần chạy kiểm tra độ mạnh mẽ random-move, và 2000-2059 cho Experiment 2) để tái lập được. Chúng tôi giữ nguyên toàn bộ số liệu trên phần cứng đơn-lõi này cho bản thảo hiện tại; tỷ lệ timeout quan sát được (20-22%, Mục 7.1) là một đặc tính riêng của thiết lập phần cứng/ngân sách node cụ thể này và nhiều khả năng sẽ thấp hơn trên phần cứng nhiều lõi/nhanh hơn — đây là một giới hạn đã biết của kết quả, không phải một thuộc tính phổ quát của Trigger-Biased Search, và nên được nêu rõ nếu công bố chính thức dùng phần cứng khác.

Kiểm định thống kê. Kiểm định Wilcoxon signed-rank (theo cặp, từng scramble) cho khác biệt về số nước và HLI giữa các điều kiện; báo cáo effect size $r = Z/\sqrt{N}$.

6 Kết quả

6.1 Experiment 1: Khoảng cách giống-người cơ sở

Bảng 1 báo cáo kết quả trên $N = 60$ scramble random-state kiểu WCA (Mục 5: random walk dài, nghịch đảo lời giải Kociemba gần-tối-ưu; seed 5000–5059), được chọn làm kết quả chính vì khớp sát hơn với phương pháp sinh scramble thi đấu thật. Nhóm A dùng ngân sách node F2L đã giảm (40.000 node/độ sâu, từ mặc định 120.000) và timeout 20 giây thực cho mỗi lần giải để phù hợp với phần cứng đánh giá đơn-lỗi của chúng tôi; 20% scramble (12/60) vượt quá timeout này và bị loại khỏi thống kê theo cặp bên dưới. Trong số 48 scramble được cả hai nhóm giải, kiểm định Wilcoxon signed-rank xác nhận Nhóm A cần số nước nhiều hơn có ý nghĩa so với Nhóm B ($W = 0$, $p = 1,61 \times 10^{-9}$, $r = 0,87$, effect size rất lớn), trong khi theo cấu trúc chỉ Nhóm A có HLI khác 0. Chúng tôi cũng chạy lại cùng phép so sánh trên $N = 100$ scramble random-move làm kiểm tra độ mạnh mẽ (robustness check) — kết quả gần như giống hệt, bao gồm một hiện tượng tìm kiếm không hội tụ đáng chú ý (22% timeout); xem Mục 7.1 và 8 để thảo luận chi tiết về kiểm tra này.

Table 1: Nhóm A (AI-CFOP) so với Nhóm B (Kociemba), $N=60$ scramble random-state kiểu WCA, 48 cặp thành công (Wilcoxon $p = 1,61 \times 10^{-9}$, $r = 0,87$ cho khác biệt số nước)

	Nhóm A (AI-CFOP)	Nhóm B (Kociemba)
Số nước TB (sd)	66,3 (9,5)	20,6 (0,9)
Khoảng số nước	53–104	18–22
HLI TB (sd)	0,658 (0,093)	0 (theo định nghĩa)
Tỷ lệ giải thành công	80% (20% timeout)	100%

6.2 Experiment 2: Đánh đổi Pareto của Trigger-Biased Search

Hình 1 cho thấy kết quả trên $N = 60$ scramble ($\lambda \in \{0; 0,5; 1,0\}$, chỉ giai đoạn F2L, ngân sách 40.000 node). Tăng λ từ 0 lên 1,0 nâng độ trùng lặp trigger trung bình từ $0,090 \pm 0,089$ lên $0,255 \pm 0,135$ (tăng $2,8\times$) với chi phí số nước từ $25,7 \rightarrow 27,6$ nước ($+7,4\%$), trong khi thời gian tính trung bình tăng từ $2,77s$ lên $7,87s$. Trên $n = 51$ scramble được giải ở cả $\lambda = 0$ và $\lambda = 1,0$, kiểm định Wilcoxon signed-rank theo cặp xác nhận cả hai khác biệt đều có ý nghĩa thống kê: độ trùng lặp trigger ($W = 29,0$, $p = 8,25 \times 10^{-8}$, $r = 0,83$, effect size rất lớn) và số nước ($W = 209,5$, $p = 0,0014$, $r = 0,60$, effect size lớn). Đáng

chú ý, $\lambda = 0,5$ cho thời gian giải *tối đa* quan sát được (55,5s) cao hơn $\lambda = 1,0$ (55,6s, tương đương), và cả hai đều cao hơn nhiều so với mức tối đa của $\lambda = 0$ (16,5s) — nhất quán với chi phí thời gian tính toán phi tuyến, đôi khi nghiêm trọng, của việc thiên vị một heuristic vốn gần-admissible ra khỏi tính admissible (Mục 7).




Figure 1: Độ trùng lặp trigger và số nước đi theo hàm của λ ($N=60$ scramble). Panel (c) cho thấy đường biên Pareto thực nghiệm.

6.3 Experiment 3: Kiểm định bằng giám khảo con người (kiểu BotPrize)

Theo Hingston [2], chúng tôi thực hiện một nghiên cứu giám khảo con người mù để kiểm tra construct validity của HLI. 24 mẫu (6 mẫu mỗi nhóm từ Nhóm H [lời giải CFOP người thật thật sự, tự thu thập và đã kiểm chứng giải đúng scramble tương ứng], Nhóm A, Nhóm A+ [$\lambda = 1,0$], và Nhóm B) được trình bày dưới dạng chuỗi nước đi thô, không phân đoạn (không có nhãn giai đoạn, để giữ tính mù) cho 28 người chấm biết CFOP, mỗi người chấm điểm mọi mẫu trên thang 1-5 "khả năng đây là lời giải người thật" thông qua một công cụ web tự xây dựng (kho T ở Mục 4.1 được tái sử dụng cho điểm so sánh trigger-overlap tự động).

Xếp hạng nhóm. Điểm giống-người trung bình theo đúng thứ tự dự đoán: Nhóm H ($3,88 \pm 0,11$) > Nhóm A+ ($3,71 \pm 0,16$) > Nhóm A ($3,42 \pm 0,16$) > Nhóm B ($2,37 \pm 0,19$). Kiểm định Mann-Whitney U so sánh Nhóm B với các nhóm còn lại gộp chung cho thấy tách biệt hoàn toàn về thứ hạng ($U = 0$, $n_1 = 6$, $n_2 = 18$, $p = 1,8 \times 10^{-4}$) — mọi mẫu Nhóm B đều được chấm giống-người thấp hơn mọi mẫu ngoài Nhóm B, xác nhận người chấm nhận diện đáng tin cậy baseline tối-ưu-kiểu-máy-tính là không phải người.

Thiên vị trigger thu hẹp khoảng cách xuống mức không phân biệt được với người. Kiểm định Mann-Whitney theo cặp cho kết quả then chốt: Nhóm A so với Nhóm A+ khác biệt có ý nghĩa ($p = 0,030$), xác nhận người chấm cảm nhận được hiệu ứng của Trigger-Biased Search, không chỉ là chỉ số tự động; nhưng Nhóm H

so với Nhóm A+ *không* khác biệt có ý nghĩa ($p = 0,109$), trong khi Nhóm H so với Nhóm A thì có ($p = 0,005$). Nói cách khác, $\lambda = 1,0$ đã đưa các lời giải do AI sinh ra từ trạng thái phân-biệt-được-về-thống-kê-với-người-thật sang trạng thái không-phân-biệt-được-về-thống-kê-với-người-thật trên mẫu này — một “pass” kiểu BotPrize cho điều kiện có thiên vị trigger mà baseline không thiên vị không đạt được.

Construct validity của HLI (RQ-V1). Chúng tôi báo cáo hai phiên bản của tương quan này. Dùng một proxy đơn giản hóa ban đầu theo từng mẫu (Segmentability/Pattern-conformity giả định bằng 1 cho Nhóm A/A+ và bằng 0 cho Nhóm B/H, chỉ dựa trên tư cách thành viên nhóm), tương quan Spearman giữa HLI và điểm đánh giá người trung bình trên toàn bộ 24 mẫu là $\rho = 0,440$ ($p = 0,031$). Tuy nhiên, proxy này đã mô tả sai Nhóm H: vì các lời giải CFOP người thật bị giả định là không có cấu trúc CFOP theo cùng logic dùng cho baseline máy tính, HLI của họ bị đánh giá thấp giả tạo (ví dụ 0,05–0,14) dù nhận điểm đánh giá con người cao nhất. Do đó chúng tôi đã tính lại Segmentability và Pattern-conformity một cách *chính xác*, bằng cách phát lại chuỗi nước đi của mỗi mẫu trên trạng thái xuất phát (đã scramble) thực tế của nó và kiểm chứng, theo đúng thứ tự, các hậu-điều-kiện Cross, F2L, và OLL (Mục 4), và bằng cách kiểm tra xem các trạng thái con OLL/PLL kết quả có khớp với các mục trong bảng thuật toán chuẩn đã kiểm chứng của chúng tôi hay không. Điều này xác nhận Nhóm B có Segmentability= 0 cho cả 6 mẫu (đúng như kỳ vọng — các lời giải gần-tối-ưu của Kociemba đạt Cross, F2L, và OLL/PLL gần như đồng thời trong 1–2 nước cuối, không bao giờ thể hiện cấu trúc trung gian được phân giai đoạn thật sự), trong khi cả 18 mẫu Nhóm A/A+/H đều có Segmentability= 1, với Pattern-conformity dao động có ý nghĩa trong mỗi nhóm (0,5 hoặc 1,0, tùy case con OLL và/hoặc PLL có khớp với bảng của chúng tôi hay không). Với phép tính chính xác này, tương quan *mạnh lên* thành $\rho = 0,487$ ($p = 0,016$) — có ý nghĩa hơn ước lượng proxy, xác nhận kỳ vọng của chúng tôi rằng proxy nhị phân theo nhóm đã làm loãng thay vì phản ánh đúng construct validity thật sự. Riêng thành phần trigger-overlap vẫn tương quan mạnh nhất với đánh giá con người ($\rho = 0,605$, $p = 0,0017$), cho thấy nó vẫn là thành phần liên quan nhất đến đánh giá con người của HLI trong mẫu này, với Segmentability và Pattern-conformity đóng góp tích cực nhưng yếu hơn.

7 Thảo luận

Trái với trực giác, ban đầu chúng tôi giả thuyết rằng việc làm yếu tính admissible của heuristic thông qua số hạng bonus trigger không-admissible sẽ *làm tăng* tình trạng không hội tụ của tìm kiếm khi λ cao hơn. Dữ liệu cho thấy điều ngược lại: trên cùng $N = 60$ scramble dùng cho Hình 1, tỷ lệ *thất bại* của tìm kiếm (hết ngân sách node ở mọi

độ sâu bậc thang) là 15,0% tại $\lambda = 0$, giảm xuống 1,7% tại $\lambda = 0,5$ và 0% tại $\lambda = 1,0$. Một cách giải thích hợp lý là bonus trigger, dù không-admissible, đóng vai trò như một hình thức *định hướng thứ tự tìm kiếm*: các nhánh mở rộng một trigger con người đã biết được khám phá sớm hơn trong hàng đợi ưu tiên (f' thấp hơn), và vì trigger là các chuỗi nước đi ngắn, đã được kiểm nghiệm kỹ, tạo tiến triển cục bộ đáng tin cậy, việc theo chúng có thể giảm hệ số phân nhánh hiệu quả trong thực tế dù bonus không phải là một ước lượng khoảng cách hợp lệ. Điều này không mâu thuẫn với chi phí *thời gian* phi tuyến đã quan sát riêng ở λ cao hơn (Mục 6): tính hội tụ có vẻ đáng tin cậy hơn, nhưng các lần chạy trường-hợp-xấu-nhất cá biệt vẫn có thể mất thời gian lâu hơn đáng kể, tức là thiên vị trigger đánh đổi *độ tin cậy* hội tụ để lấy *phương sai* thời gian tìm kiếm. Chúng tôi lưu ý phát hiện này dựa trên $N = 60$ scramble và chỉ ba mức λ (0; 0,5; 1,0); chúng tôi chưa xác nhận xu hướng này ổn định trên cỡ mẫu lớn hơn hoặc các mức λ trung gian (ví dụ 0,25; 0,75), và xem đây là một hạn chế cần làm rõ thêm ở công việc tiếp nối (Mục 9) trước khi khẳng định chắc chắn trong một bản công bố chính thức. Một phân tích hình thức về việc chính xác mất bao nhiêu tính admissible được trình bày dưới đây.

Mất bao nhiêu tính admissible? Heuristic gốc $h(n) = h_{\text{PDB}}(n) + \text{penalty}(n)$ vốn cũng không hoàn toàn admissible (số hạng penalty đã hy sinh đảm bảo cận-dưới hình thức để đổi lấy tính thực tiễn), nên Trigger-Biased Search không tạo ra vi phạm tính admissible *từ đầu* — nó cộng dồn thêm vào một đánh đổi thiết kế có chủ đích đã tồn tại từ trước. Về mặt hình thức, với một đường đi $\text{path}(n)$ có độ dài $g(n)$, $\text{bonus}(\text{path}(n)) \in [0, g(n)]$ (nó có thể bao phủ tối đa mọi nước đi trong đường đi), nên độ đánh giá thấp bổ sung tối đa mà số hạng bonus có thể gây ra bị chặn bởi $\lambda \cdot g(n)$ — tức là độ méo tiềm năng tăng *tuyến tính theo độ sâu đường đi*, không phải theo một hằng số cố định, đây là một kiểu thất bại khác về bản chất (và đáng lo ngại hơn) so với một heuristic có sai số bị chặn. Điều này giải thích vì sao, khác với tìm kiếm bounded-suboptimal cổ điển (ví dụ weighted A* với hệ số lạm phát cố định và cận suboptimality chứng minh được), chúng tôi hiện chưa cung cấp cận hình thức nào cho tính suboptimal về độ dài lời giải của Trigger-Biased Search; Mục 6 thay vào đó báo cáo điều này bằng thực nghiệm (trung bình +7,4% số nước tại $\lambda = 1,0$). Một biện pháp giảm nhẹ tự nhiên, để dành cho công việc tương lai, là giới hạn bonus ở một mức tối đa cố định (ví dụ $\min(\text{bonus}(\text{path}(n)), c)$ cho hằng số c nào đó), điều này sẽ khôi phục lại một độ méo bị chặn cố định tương tự như số hạng penalty hiện có.

7.1 Scramble bệnh lý và tình trạng tìm kiếm không hội tụ

Trong lần chạy kiểm tra độ mạnh mẽ dùng $N = 100$ scramble random-move (Mục 8), 22% scramble (22/100) không hoàn thành trong ngân sách 20 giây thực ngay cả với ngân sách tìm kiếm đã giảm còn 40.000 node/độ sâu — đáng chú ý, một số thất bại như vậy xảy ra liên tiếp nhau (ví dụ seed 1059-1061 trong lần chạy của chúng tôi), gợi ý bộ sinh scramble random-move có thể tạo ra các chuỗi cấu hình F2L tương tự nhau về cấu trúc, mang tính đối kháng, thay vì độ khó độc lập đồng phân bố (i.i.d.). Một seed cụ thể (1013) bị treo hơn 5 phút ngay cả với ngân sách đã giảm, trước khi chúng tôi đưa vào một timeout thực cứng (dựa trên SIGALRM) trong bộ khai thác đánh giá. Chúng tôi diễn giải điều này là bằng chứng cho thấy heuristic A* có bổ sung penalty theo từng cặp dùng cho F2L (Mục 5) đôi khi bị dẫn vào các vùng tìm kiếm không hiệu quả một cách bệnh lý — một giới hạn về độ tin cậy quan trọng, khác biệt với, nhưng có thể bị khuếch đại bởi, cơ chế thiên vị trigger ở Mục 4. Lưu ý cả lần chạy chính (random-state, Bảng 1) lẫn lần chạy kiểm tra này đều dùng $\lambda = 0$ xuyên suốt (không áp thiên vị trigger cho giai đoạn F2L); chúng tôi đo riêng mối quan hệ giữa λ và tỷ lệ thất bại hội tụ dùng dữ liệu Experiment 2 (Mục 7), phát hiện — trái với kỳ vọng ban đầu — rằng λ cao hơn liên quan đến *ít hơn*, không phải nhiều hơn, các thất bại hội tụ trên tập dữ liệu đó.

8 Đe dọa đến Tính hợp lệ (Threats to Validity)

- **Tìm kiếm không hội tụ:** như đã báo cáo ở Mục 7.1, 22% scramble trong lần chạy kiểm tra độ mạnh mẽ random-move ($N = 100$) và 20% scramble trong lần chạy chính random-state ($N = 60$, Bảng 1) không hoàn thành trong timeout 20 giây ở thiết lập phần cứng/ngân sách đánh giá của chúng tôi; kết quả có điều kiện trên các scramble đã hoàn thành, có thể không phải là mẫu con đại diện (ví dụ nếu độ khó tương quan với tiềm năng trigger-overlap).
- **Construct validity của HLI:** chỉ số này được thiết kế thủ công, đã được validate đối chiếu với đánh giá con người thông qua Experiment 3 (Mục 6.3).
- **Độ tin cậy liên giám khảo:** từng giám khảo cá nhân có độ đồng thuận khiêm tốn ($\text{ICC}(2,1) = 0,26$, dưới ngưỡng 0,4 thường dùng làm mốc “đồng thuận chấp nhận được”), nhưng nhờ cỡ mẫu $N = 28$ người chấm, điểm trung bình dùng cho các phân

tích tương quan ở Mục 6.3 đạt độ tin cậy cao ($ICC(2,k) = 0,91$) – tương quan RQ-V1 nên được diễn giải như tương quan của một điểm trung bình ổn định, không phải của phán đoán từng cá nhân đơn lẻ.

- **Thiên vị kho ngữ liệu:** kho finger-trick T được tuyển chọn thủ công (11 trigger), không được suy ra từ log solve người thật; kết quả có thể không tổng quát hóa được cho các solver có vốn trigger khác.
- **Sinh scramble (đã kiểm tra):** Bảng 1 (Mục 6) dùng bộ sinh scramble kiểu WCA random-state (Mục 5) làm kết quả chính, vì khớp sát hơn với phương pháp sinh scramble thi đấu thật. Chúng tôi cũng chạy lại Experiment 1 trên $N = 100$ scramble random-move (seed 1000–1099, bộ sinh dùng cho Experiment 2) như một kiểm tra độ mạnh mẽ (robustness check). Kết quả nhất quán giữa hai bộ sinh (78% so với 80% tỷ lệ giải thành công; số nước trung bình 67,2 so với 66,3; HLI trung bình 0,655 so với 0,658), cho thấy kết quả chính không phải là hiện tượng giả tạo do lựa chọn bộ sinh scramble cụ thể. Bộ random-move này cũng là nơi chúng tôi quan sát thấy hiện tượng tìm kiếm không hội tụ đáng chú ý (22% timeout, xem Mục 7.1); chúng tôi chưa quan sát cụm thất bại tương tự trên $N = 60$ mẫu random-state (tỷ lệ timeout thấp hơn, 20%), nhưng cỡ mẫu nhỏ hơn khiến việc so sánh trực tiếp về tính “cụm” của thất bại giữa hai bộ sinh chưa đủ mạnh để kết luận chắc chắn.
- **Khả năng tổng quát hóa đơn-miễn:** kết quả đặc thù cho Rubik’s Cube; các tuyên bố về explicability nói chung nên được giới hạn tương ứng.

9 Công việc Tương lai

Tái lập độc lập việc tính lại HLI chính xác. Phép tính Segmentability/Pattern-conformity chính xác trong Mục 6.3 (`research/phase3_survey/recompute_hli_exact.py`) dựa trên một cách hiện thực hóa cụ thể, đã kiểm chứng thủ công của “ranh giới giai đoạn” (chỉ số nước đi đầu tiên mà một hậu-điều-kiện được thỏa mãn, với thứ tự chặt giữa các giai đoạn — xem `docstring` của script để biết lý do cho lựa chọn cụ thể này so với các phương án khác chúng tôi từng thử và loại bỏ ban đầu). Một cài đặt lại độc lập, hoặc validate đối chiếu với ranh giới giai đoạn chuẩn được gán nhãn thủ công cho một tập con mẫu, sẽ củng cố độ tin cậy của thành phần này trong pipeline.

Tái lập quy mô lớn hơn. $N = 24$ mẫu là đủ cho một nghiên cứu pilot nhưng khiêm tốn cho việc ước lượng effect-size chính xác; một

ngiên cứu tiếp nối với nhiều mẫu hơn mỗi nhóm (đặc biệt nhiều lời giải Nhóm H hơn từ một nhóm người đóng góp rộng hơn, để giảm phụ thuộc vào thói quen của một solver đơn lẻ) sẽ thu hẹp khoảng tin cậy trên các so sánh nhóm ở Mục 6.3.

Mở rộng pattern-conformity sang Cross/F2L. Hiện tại Pattern-conformity $P(\pi)$ chỉ áp dụng cho OLL/PLL, vì đây là hai giai đoạn duy nhất có bảng case-sang-thuật-toán hữu hạn, có tên trong hệ thống của chúng tôi; Cross và F2L được đo gián tiếp qua Trigger-overlap thay vì Pattern-conformity thật sự. Xây dựng một bảng case F2L chuẩn (ví dụ theo hệ thống 41-case phổ biến trong cộng đồng speedcubing) và một cơ chế nhận diện case tương tự `verify_and_build_table()` đã dùng cho PLL sẽ cho phép thay thế một phần Trigger-overlap bằng Pattern-conformity thật sự cho F2L, làm HLI phản ánh chính xác hơn cấu trúc của giai đoạn này.

Cơ chế thiên vị thay thế. Trigger-Biased Search hiện dùng một siêu tham số λ cố định, chọn thủ công. Công việc tiếp nối có thể so sánh cơ chế này với các phương án khác, ví dụ: tinh chỉnh trực tiếp trọng số của pattern database dùng cho F2L thay vì cộng thêm một số hạng bonus riêng biệt, hoặc học trọng số `bonus(path)` từ dữ liệu solve người thật (ví dụ hồi quy tần suất trigger quan sát được trong log CSTimer) thay vì ấn định λ bằng tay – qua đó biến kho hạt giống T (Phụ lục A) từ một danh sách tuyển chọn thủ công thành một mô hình được học trực tiếp từ hành vi người giải thật.

10 Kết luận

Các solver Rubik’s Cube hiện có tối ưu hóa cho số nước đi, tạo ra các kế hoạch đúng nhưng không thể diễn giải được đối với người học; các speedcuber con người thay vào đó dùng CFOP, đánh đổi tính tối ưu để lấy cấu trúc và khả năng học được. Chúng tôi đã hình thức hóa sự đánh đổi này bằng ngôn ngữ của lập kế hoạch AI nhận biết con người thành một *Chỉ số Giống-Người* (HLI) đo lường được, và cho thấy bằng thực nghiệm ($N = 60$ scramble random-state, kiểm tra độ mạnh mẽ trên $N = 100$ scramble random-move) rằng solver AI-CFOP của chúng tôi đạt điểm cao hơn đáng kể trên chỉ số này so với baseline Kociemba tối-ưu-kiểu-máy-tính (HLI trung bình 0,658 so với 0 theo định nghĩa), một khoảng cách robust trên một phạm vi rộng các cách gán trọng số thành phần (Mục 4). Sau đó chúng tôi giới thiệu *Trigger-Biased A* Search*, một cải tiến tối giản, tương thích ngược cho heuristic F2L làm hơn gấp đôi độ trùng lặp trigger với các pattern finger-trick con người (từ 9,0% lên 25,5% tại $\lambda = 1,0$) với chi phí số nước khiêm tốn (+7,4%), trong khi — trái với trực giác — lại *cải thiện* độ tin cậy hội

tự tìm kiếm trên tập kiểm thử của chúng tôi, với cái giá là tăng thời gian tính toán trường-hợp-xấu-nhất. Trong quá trình đó, chúng tôi đã phát hiện và báo cáo minh bạch một hiện tượng tìm kiếm không hội tụ (22% tỷ lệ timeout) tạo thành một giới hạn cụ thể về độ tin cậy của tìm kiếm heuristic có bổ sung penalty trong miền này. Cuối cùng, một nghiên cứu giám khảo con người mù ($N = 24$ mẫu, 28 người chấm, Mục 6.3) đã cung cấp bằng chứng trực tiếp cho construct validity của HLI ($\rho = 0,487$, $p = 0,016$) và, đáng chú ý hơn, cho thấy Trigger-Biased Search đưa các lời giải AI-CFOP từ trạng thái phân-biệt-được-về-thống-kê-với-người-thật ($p = 0,005$) sang trạng thái không-phân-biệt-được-về-thống-kê-với-người-thật ($p = 0,109$) trong đánh giá mù của con người — một minh chứng cụ thể, đã được xác thực bởi con người, rằng việc tối ưu hóa tường minh cho các pattern con người có thể nhận ra, thay vì chỉ số nước đi, thay đổi một cách đo lường được cách người quan sát nhìn nhận các lời giải do AI tạo ra. Chúng tôi hy vọng công trình này khuyến khích thêm sự giao thoa giữa AI tìm kiếm tổ hợp cổ điển và nghiên cứu AI nhận biết con người/AI giải thích được trong các miền câu đố lớn, đã được hiểu rõ như Rubik’s Cube.

References

- [1] T. Chakraborti, A. Kulkarni, S. Sreedharan, D. E. Smith, và S. Kambhampati. Explicability? legibility? predictability? transparency? privacy? security? the emerging landscape of interpretable agent behavior. Trong *Proceedings of the International Conference on Automated Planning and Scheduling (ICAPS)*, 2019.
- [2] P. Hingston. A turing test for computer game bots. *IEEE Transactions on Computational Intelligence and AI in Games*, 1(3):169–186, 2009.
- [3] H. Kociemba. Cube explorer / two-phase algorithm. <http://kociemba.org/cube.htm>, truy cập ngày 26 tháng 7 năm 2026.
- [4] R. E. Korf. Finding optimal solutions to rubik’s cube using pattern databases. Trong *Proceedings of the National Conference on Artificial Intelligence (AAAI)*, 1997.
- [5] A. Kulkarni, Y. Zha, T. Chakraborti, S. G. Vadlamudi, Y. Zhang, và S. Kambhampati. Explicable robot planning as minimizing distance from expected behavior. *arXiv preprint arXiv:1611.05497*, 2016.

- [6] S. McAleer, F. Agostinelli, A. Shmakov, và P. Baldi. Solving the rubik’s cube without human knowledge. *arXiv preprint arXiv:1805.07470*, 2018.
- [7] T. Rokicki, H. Kociemba, M. Davidson, và J. Dethridge. The diameter of the rubik’s cube group is twenty. *SIAM Review*, 56(4):645–670, 2014.
- [8] M. Świechowski và D. Ślęzak. The many challenges of human-like agents in virtual game environments. Trong *Proceedings of the 24th International Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, trang 1996–2004. IFAAMAS, 2025. Cũng có trên arXiv preprint arXiv:2505.20011.
- [9] K. Lakkaraju, T. Hassan, V. Khandelwal, P. Singh, C. Bradley, R. Shah, và cộng sự, và D. Wu. Allure: A multi-modal guided environment for helping children learn to solve a rubik’s cube with automatic solving and interactive explanations. Trong *Proceedings of the AAAI Conference on Artificial Intelligence*, tập 36, trang 13185–13187, 2022.
- [10] K. Vanacore, J. Ocumpaugh, F. Agostinelli, D. Wu, S. Vuruma, và M. Irvin. Student engagement in ai-assisted complex problem solving: A pilot study of human-ai rubik’s cube collaboration. *arXiv preprint arXiv:2511.01683*, 2025. Ghi chú: bản thảo chưa công bố, bài báo đang chuẩn bị nộp tại thời điểm viết bài – kiểm tra lại tình trạng công bố trước khi trích dẫn như một nguồn đã bình duyệt.
- [11] Y. Zhang, S. Sreedharan, A. Kulkarni, T. Chakraborti, H. H. Zhuo, và S. Kambhampati. Plan explicability and predictability for robot task planning. Trong *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, 2017.

A Kho hạt giống T : 11 finger-trick

Bảng 2 liệt kê đầy đủ kho hạt giống T dùng để tính Trigger-overlap $O(\pi)$ và số hạng bonus(path) trong Trigger-Biased Search (Mục 4.1, 4), trích trực tiếp từ `research/finger_tricks.py`. Mỗi trigger được liệt kê ở dạng “thuận” (R-based); hệ thống tự sinh thêm biến thể mirror (L-based, hoán đổi $R \leftrightarrow L$) khi khớp mẫu.

Table 2: Kho hạt giống T ($|T| = 11$)

Tên	Chuỗi nước đi
sexy_move	$R U R' U'$
sexy_move_inv	$U R U' R'$
reverse_sexy	$R' U' R U$
sledgehammer	$R' F R F'$
sledgehammer_inv	$F R' F' R$
hedgehog	$R U' R'$
triple_sexy	$(R U R' U')^3$
sune_trigger	$R U R' U R U^2 R'$
ubl_insert	$U' R U$
urf_insert	$U R U'$
niklas	$R U R' U' R' F R F'$