

Đo lường và Cải thiện Tính Giống-Người của Lời giải CFOP do AI Sinh ra cho Rubik's Cube: Phương pháp Trigger-Biased Search

[VIỆC CẦN LÀM: Tên tác giả]
[VIỆC CẦN LÀM: Đơn vị / Trường]
[VIỆC CẦN LÀM: email]

Abstract

Các phương pháp tính toán hiện có để giải Rubik's Cube — bao gồm tìm kiếm bằng pattern-database [4], các solver tối ưu dựa trên lý thuyết nhóm [7, 3], và học tăng cường [6] — hầu như chỉ tối ưu hóa số nước đi, tạo ra các lời giải đúng nhưng phần lớn không thể diễn giải được đối với người học. Ngược lại, phương pháp CFOP do con người thiết kế (Cross, F2L, OLL, PLL) đánh đổi tính tối ưu về số nước đi lấy *khả năng học được*, được cấu trúc quanh một tập hữu hạn các pattern chuỗi-nước-đi dễ nhớ ("thuật toán"). Chúng tôi hình thức hóa khái niệm *tính giống người* của một kế hoạch giải cube bằng ngôn ngữ của lập kế hoạch AI nhận biết con người (human-aware AI planning) [5, 1], đề xuất một *Chỉ số Giống-Người* (Human-Likeness Index — HLI) tổng hợp từ ba thành phần đo lường được (khả năng phân đoạn giai đoạn, độ khớp mẫu-thuật-toán-có-tên, và độ trùng lặp finger-trick), và giới thiệu *Trigger-Biased A* Search*, một cải tiến heuristic-search thưởng rõ ràng cho các nhánh tìm kiếm trùng khớp với kho finger-trick của con người. Các thí nghiệm thực nghiệm (N=100 cho so sánh cơ sở, N=60 cho quét Pareto) cho thấy việc thiên vị heuristic tìm kiếm F2L làm tăng độ trùng lặp trigger từ mức cơ sở 9,0% lên 25,5% tại $\lambda = 1,0$ (Wilcoxon $p = 8,3 \times 10^{-8}$), với chi phí chỉ 7,4% số nước tăng thêm (Wilcoxon $p = 0,0014$), cho thấy một sự đánh đổi Pareto thuận lợi (dù phi tuyến về thời gian tính toán). Một nghiên cứu giám khảo con người mù, kiểu BotPrize [2] (24 mẫu, 28 người chấm) xác nhận construct validity của HLI (Spearman $\rho = 0,487$, $p = 0,031$ so với điểm đánh giá giống-người trung bình) và cho thấy Trigger-Biased Search đưa các lời giải do AI sinh ra từ trạng thái *phân biệt được về mặt thống kê với người thật* ($p = 0,005$) sang *không phân biệt được về mặt thống kê với người thật* ($p = 0,109$) trong đánh giá mù. Theo hiểu biết của chúng tôi, đây là nghiên

cứu đầu tiên áp dụng các chỉ số kiểu explicability vào một miền tìm kiếm tổ hợp quy mô lớn, kết nối AI tìm kiếm heuristic cổ điển với nghiên cứu AI nhận biết con người và AI tác nhân đáng tin (believable-agent AI).

1 Giới thiệu

Giải Rubik's Cube từ lâu đã là một miền benchmark cho tìm kiếm heuristic và tối ưu hóa tổ hợp [4, 7], và gần đây hơn là cho học tăng cường tự chơi (self-play reinforcement learning) [6]. Các phương pháp này có chung một mục tiêu: tối thiểu hóa số nước đi (hoặc tối đa hóa tỷ lệ thắng trước một bộ sinh scramble đối kháng), không quan tâm liệu lời giải thu được có tương ứng với bất kỳ pattern nào mà con người có thể học, ghi nhớ, hoặc giải thích hay không.

Ngược lại, các speedcuber con người sử dụng các phương pháp có cấu trúc như CFOP (Cross, F2L, OLL, PLL), chủ động đánh đổi tính tối ưu về số nước để lấy *khả năng học được*: mỗi giai đoạn được rút gọn thành việc nhận diện một trong số hữu hạn các "case" chuẩn, mỗi case đi kèm một thuật toán cố định, có tên. Phương pháp CFOP đầy đủ gồm 57 case OLL có tên và 21 case PLL có tên; một biến thể rút gọn được dùng rộng rãi ("2-look OLL/PLL") giải mỗi giai đoạn qua hai lượt tuần tự dùng một tập con nhỏ hơn nhiều các thuật toán, với cái giá là tốn thêm nước đi. Hệ thống của chúng tôi cài đặt một bảng đã kiểm chứng đầy đủ 21 case PLL (Mục 4.1) nhưng chỉ có OLL 2-look (2 thuật toán sinh, Sune/Anti-Sune, thay vì đầy đủ 57 case); sự bất đối xứng này tự nó có giá trị thông tin cho việc đo lường Pattern-conformity (Mục 4).

[VIỆC CẦN LÀM: Đoạn này tóm tắt khoảng trống nghiên cứu - xem phần Related Work bên dưới, viết lại ngắn gọn ở đây, kết bằng câu dẫn vào contributions]

Đóng góp. Bài báo này có các đóng góp sau:

1. Một hình thức hóa *tính giống người* cho các kế hoạch giải cube, dựa trên khái niệm explicability của lập kế hoạch nhận biết con người [5, 1], cụ thể hóa thành **Chỉ số Giống-Người (HLI)** tổng hợp với ba thành phần đo lường được, tái lập được (Mục 4).
2. **Trigger-Biased A* Search**: một cải tiến tối giản, tương thích ngược đối với A* search dẫn dắt bởi pattern-database cho F2L, tối ưu hóa rõ ràng cho độ trùng lặp finger-trick con người thông qua một siêu tham số λ duy nhất, dễ diễn giải (Mục 4).
3. Một phân tích Pareto thực nghiệm về sự đánh đổi giữa tính giống-người / số nước đi / thời gian tính toán do λ gây ra (Mục 6).

4. Một nghiên cứu giám khảo con người mù, kiểu BotPrize [2] (24 mẫu, 28 người chấm) vừa construct-validate HLI đối chiếu với đánh giá con người, vừa cho thấy Trigger-Biased Search thu hẹp khoảng cách giống-người xuống mức không phân biệt được về thống kê so với lời giải người thật (Mục 6.3).

2 Công trình liên quan

2.1 Các solver Rubik's Cube tối ưu kiểu máy tính

IDA* của Korf kết hợp pattern database cộng dồn [4] là phương pháp đầu tiên tìm được lời giải tối ưu chứng minh được cho scramble bất kỳ. Rokicki và cộng sự [7] đã chứng minh mọi trạng thái cube đều giải được trong tối đa 20 nước xoay mặt ("God's Number"), thông qua tìm kiếm dựa trên coset quy mô lớn. Thuật toán hai pha của Kociemba [3] đánh đổi tính tối ưu tuyệt đối để lấy thời gian chạy khả thi, thường trả về lời giải chỉ cách tối ưu 1-4 nước, và là baseline chúng tôi dùng trong Mục 5. McAleer và cộng sự [6] cho thấy một tác nhân học tăng cường (DeepCubeA) có thể học giải cube mà không cần tri thức con người có sẵn, đạt độ dài lời giải gần tối ưu. Không phương pháp nào trong số này tạo ra kế hoạch có thể phân đoạn, có tên, hay diễn giải được theo cách con người học có thể nhận ra — chúng tôi, theo thuật ngữ của chúng tôi, mang tính *computer-like* tối đa.

2.2 Lập kế hoạch nhận biết con người và explicability

Một hướng nghiên cứu riêng trong lập kế hoạch AI nghiên cứu cách các tác nhân tự động nên hành xử khi được quan sát hoặc hỗ trợ bởi con người có một mô hình tinh thần nội tại, có thể không hoàn hảo, về tác nhân đó. Kulkarni và cộng sự [5] hình thức hóa *explicability* là việc tối thiểu hóa khoảng cách giữa kế hoạch thực tế của tác nhân và kế hoạch mà người quan sát kỳ vọng, và đề xuất các sửa đổi tìm kiếm thiên vị việc lập kế hoạch hướng tới các quỹ đạo dễ giải thích hơn — về cấu trúc tương tự heuristic thiên vị-trigger mà chúng tôi đề xuất trong Mục 4, nhưng áp dụng ở đây cho lập kế hoạch tác vụ ký hiệu thay vì một miền câu đố tổ hợp quy mô lớn. Chakraborti và cộng sự [1] khảo sát bối cảnh này (*explicability*, *legibility*, *predictability*, *transparency*), mà chúng tôi dùng làm từ vựng lý thuyết cho bài báo này. **[VIỆC CẦN LÀM: Nếu tìm thêm được bài liên quan (vd Zhang et al. 2017 về legibility trong lập kế hoạch tác vụ robot), thêm 1-2 câu ở đây.]**

2.3 Tính giống người / độ tin cậy của tác nhân chơi game

Độc lập với hướng trên, cộng đồng AI game từ lâu đã nghiên cứu cách làm cho tác nhân tự động *trông giống* con người. Cuộc thi 2K BotPrize [2] đã hiện thực hóa điều này thành một biến thể Turing test, trong đó giám khảo con người chấm điểm cả người chơi thật lẫn bot trên thang 1-5 về mức độ giống người, mà không được biết ai là ai. **[VIỆC CẦN LÀM: 1 câu về kết quả BotPrize 2012 (UT², MirrorBot vượt qua ngưỡng) - đã có dữ liệu từ tìm kiếm web ở bước trước, điền vào đây, PARAPHRASE không trích nguyên văn]**. Một khảo cứu gần đây [8] đóng khung nghiên cứu AI game giống-người quanh hai câu hỏi — làm sao mô hình hóa/cài đặt hành vi giống người, và làm sao đo mức độ giống người đó — mà chúng tôi dùng làm cấu trúc tổ chức cho hai đóng góp chính của bài báo này (Mục 4).

2.4 Hệ thống dạy học riêng cho CFOP

Gần với công trình của chúng tôi nhất, hệ thống ALLURE [9] kết hợp một solver tự động (tìm kiếm dựa trên DeepCubeA qua các mục tiêu con) với một chatbot gia sư tương tác để giúp người học hiểu các lời giải có thể giải thích được cho mục tiêu con White Cross của CFOP; một nghiên cứu pilot gần đây [10] (bản thảo chưa công bố tại thời điểm viết bài) phân tích các pattern tương tác của học sinh trong ALLURE qua phân cụm hành vi, báo cáo rằng chiến lược white-cross cho người mới đòi hỏi nhiều nước đi hơn đáng kể so với CFOP, mà bản thân CFOP lại đòi hỏi nhiều nước hơn các phương pháp tối ưu hoàn toàn — minh họa trực tiếp sự đánh đổi khả-năng-học/tính-tối-ưu là trọng tâm của hình thức hóa chúng tôi (Mục 3). Công trình của chúng tôi khác biệt ở (a) phạm vi — bao phủ cả bốn giai đoạn CFOP thay vì chỉ Cross — (b) cơ chế — một thiên vị tìm kiếm tường minh, điều chỉnh được (Mục 4) thay vì giải thích ngôn ngữ tự nhiên hậu-nghiệm cho các nước đi đã được tìm ra bởi một solver không ràng buộc — và (c) đánh giá — không nghiên cứu ALLURE nào báo cáo một đánh giá giống-người mà có thể so sánh với Experiment 3 của chúng tôi (Mục 6.3).

3 Hình thức hóa Bài toán

Gọi G là nhóm Rubik's Cube ($|G| \approx 4,3 \times 10^{19}$), và gọi một *kế hoạch* $\pi = (m_1, \dots, m_k)$ là một chuỗi các phép sinh xoay-mặt giải một scramble $s \in G$ cho trước. Gọi M_H là một *mô hình kỳ vọng con người*: trong bài báo này, M_H được cụ thể hóa thành (i) sự phân rã giai đoạn CFOP

(Cross $\rightarrow$ F2L $\rightarrow$ OLL $\rightarrow$ PLL), (ii) một bảng hữu hạn các thuật toán chuẩn, có tên cho OLL/PLL (Mục 4.1), và (iii) một kho T các n -gram nước-đi ngắn ("finger-trick") thường được thực hiện như một đơn vị vận động duy nhất bởi người giải (Mục 4.1).

Theo Kulkarni et al. [5], chúng tôi định nghĩa tính giống người là một khoảng cách (nghịch đảo) giữa π và hành vi mà M_H coi là tự nhiên. Chúng tôi cụ thể hóa khoảng cách này thành tổng có trọng số của ba thành phần đã chuẩn hóa, đo lường được độc lập (thay vì một hàm khoảng cách học được hoặc điều chỉnh thủ công đơn lẻ), được mô tả trong Mục 4.

4 Phương pháp

4.1 Chỉ số Giống-Người (HLI)

Khả năng phân đoạn $S(\pi) \in \{0, 1\}$. Bằng 1 khi và chỉ khi π phân rã thành bốn đoạn con liên kế, kiểm chứng độc lập được, thỏa mãn lần lượt các hậu-điều-kiện Cross, F2L, OLL, và PLL theo đúng thứ tự, và bằng 0 trong trường hợp ngược lại (ví dụ với các kế hoạch giải cube bằng một chuỗi tối ưu không phân biệt được giai đoạn, như cách các solver kiểu máy tính làm theo cấu trúc của chúng).

Độ khớp mẫu $P(\pi) \in [0, 1]$. Giới hạn ở các giai đoạn OLL và PLL (nơi tồn tại một ánh xạ case-sang-thuật-toán hữu hạn, có tên trong CFOP), $P(\pi)$ là tỷ lệ các giai đoạn đã giải mà đoạn con nước-đi tương ứng khớp chính xác với một mục trong bảng đã kiểm chứng các thuật toán chuẩn (Aa, Ab, ..., Z cho PLL; các thuật toán sinh Sune/Anti-Sune cho OLL 2-look) thay vì rơi vào tìm kiếm không cấu trúc. **[VIỆC CẦN LÀM: Trích số liệu: X/Y case PLL đã kiểm chứng, bằng chứng minh bằng `verify_and_build_table()`].**

Độ trùng lặp Trigger $O(\pi) \in [0, 1]$. Đối với các giai đoạn Cross và F2L (vốn thiếu một bảng case chuẩn trong hệ thống này, được sinh ra bởi tìm kiếm heuristic không ràng buộc), chúng tôi đo tỷ lệ số nước đi được bao phủ bởi một phép phân đoạn greedy-longest-match của π đối chiếu với một kho hạt giống T gồm $|T| = 11$ finger-trick phổ biến của con người (ví dụ "sexy move" $RU R' U'$, "sledgehammer" $R' F R F'$; kho đầy đủ trong Phụ lục **[VIỆC CẦN LÀM: X]**). **[VIỆC CẦN LÀM: GHI RÕ trong bài: đây là kho hạt giống thủ công, đề xuất mở rộng bằng thống kê n -gram trên log solve người thật (vd CTimer) ở bản mở rộng.]**

HLI tổng hợp.

$$\text{HLI}(\pi) = w_S \cdot S(\pi) + w_P \cdot P(\pi) + w_O \cdot O(\pi), \quad w_S + w_P + w_O = 1$$

Chúng tôi dùng $(w_S, w_P, w_O) = (0, 3; 0, 4; 0, 3)$ trong bản thảo này. Chúng tôi đã thực hiện một phân tích độ nhạy hậu-nghiệm dùng $N = 78$ cặp scramble (Nhóm A so với Nhóm B, Experiment 1), đo cả ba thành phần HLI cho *cả hai* nhóm — bao gồm, quan trọng nhất, độ trùng lặp trigger của Nhóm B (đo trực tiếp trên chuỗi nước đi thực tế của Kociemba, không giả định bằng 0: trung bình $0,009 \pm 0,046$, xác nhận thực nghiệm rằng một bộ tối ưu hóa không có động lực hướng tới finger-trick con người về cơ bản không bao giờ tạo ra chúng một cách tình cờ). Trên toàn bộ các bộ trọng số đã thử (năm bộ đặt tên cộng với một lượt quét $w_S \in \{0; 0, 2; \dots; 1\}$), khoảng cách HLI giữa Nhóm A và Nhóm B vẫn lớn và dương chặt, dao động từ 0,397 (trọng số thiên-về-trigger) đến 1,000 (trọng số chỉ-có-segmentability), với bộ trọng số chúng tôi chọn cho khoảng cách 0,653. Điều này cho thấy tuyên bố trung tâm của bài báo — rằng AI-CFOP giống người hơn đáng kể so với baseline tối ưu-kiểu-máy-tính — là robust với lựa chọn cụ thể của (w_S, w_P, w_O) trong bất kỳ phạm vi hợp lý nào, dù *độ lớn* của khoảng cách tự nhiên phụ thuộc vào trọng số.

4.2 Trigger-Biased A* Search

Solver F2L của chúng tôi dùng A* với heuristic $h(n) = h_{\text{PDB}}(n) + \text{penalty}(n)$, trong đó h_{PDB} là một ước lượng pattern-database đơn-quân admissible và $\text{penalty}(n)$ không khuyến khích việc làm xáo trộn các quân đã giải xong (Cross và các cặp F2L trước đó). Chúng tôi thêm một số hạng thứ ba:

$$f'(n) = g(n) + h_{\text{PDB}}(n) + \text{penalty}(n) - \lambda \cdot \text{bonus}(\text{path}(n))$$

trong đó $\text{bonus}(\text{path})$ là số nước đi trong đường đi hiện tại được bao phủ bởi một phép khớp greedy-longest-match đối chiếu với kho T (cùng quy trình khớp dùng để tính $O(\pi)$ tại thời điểm đánh giá, đảm bảo tính nhất quán giữa mục tiêu lúc tìm kiếm và chỉ số lúc đánh giá). $\lambda = 0$ khôi phục chính xác tìm kiếm gốc, không thiên vị (tương thích ngược hình thức: chúng tôi đã xác nhận cả 176 unit test có sẵn từ trước đều pass không đổi với $\lambda = 0$). Tăng λ đánh đổi tính tối ưu của tìm kiếm (và, như chúng tôi cho thấy thực nghiệm, thời gian tính toán) để lấy độ trùng lặp trigger.

5 Thiết lập Thực nghiệm

Baseline (kiểu máy tính). Thuật toán hai pha của Kociemba [3], thông qua gói Python công khai `kociemba`, chạy trên cùng scramble.

Sinh scramble. Kết quả chính dùng scramble random-move (20 nước, không lặp mặt liên tiếp) để nhất quán giữa Experiment 1-2. Chúng tôi cũng cài đặt thêm một bộ sinh scramble kiểu WCA *random-state* (random walk dài để xấp xỉ phân bố trạng thái đều, sau đó nghịch đảo một lời giải Kociemba gần-tối-ưu của trạng thái đó — đảm bảo scramble cần số nước gần với số nước tối ưu để hoàn tác, khớp với phương pháp sinh scramble thi đấu thật) và đã xác nhận kết quả nhất quán giữa hai bộ sinh (Mục 7).

Phần cứng / cài đặt. Sandbox đám mây đơn lõi (1 vCPU, 4GB RAM), Python 3.12, biểu diễn cube dựa trên NumPy. Mọi thí nghiệm dùng 1 seed gốc cố định cho mỗi điều kiện (`random.Random(seed)`, seed 1000-1099 cho Experiment 1, 2000-2059 cho Experiment 2) để tái lập được. **[VIỆC CẦN LÀM: Nếu chuyển sang máy mạnh hơn trước khi công bố chính thức, cập nhật lại thông số và CHẠY LẠI toàn bộ thí nghiệm - tỷ lệ timeout 22% có thể giảm đáng kể trên máy nhiều core/nhanh hơn, nên KHÔNG dùng nguyên số liệu này nếu đổi phần cứng.]**

Kiểm định thống kê. Kiểm định Wilcoxon signed-rank (theo cặp, từng scramble) cho khác biệt về số nước và HLI giữa các điều kiện; báo cáo effect size $r = Z/\sqrt{N}$.

6 Kết quả

6.1 Experiment 1: Khoảng cách giống-người cơ sở

Bảng 1 báo cáo kết quả trên $N = 100$ scramble random-move (20 nước mỗi scramble, seed 1000-1099). Nhóm A dùng ngân sách node F2L đã giảm (40.000 node/độ sâu, từ mặc định 120.000) và timeout 20 giây thực cho mỗi lần giải để phù hợp với phần cứng đánh giá đơn-lõi của chúng tôi; 22% scramble (22/100) vượt quá timeout này và bị loại khỏi thống kê theo cặp bên dưới (xem Mục 7.1 để thảo luận về hiện tượng này). Trong số 78 scramble được cả hai nhóm giải, kiểm định Wilcoxon signed-rank xác nhận Nhóm A cần số nước nhiều hơn có ý nghĩa so với Nhóm B ($W = 0$, $p = 1,65 \times 10^{-14}$, $r = 0,87$, effect size rất lớn), trong khi theo cấu trúc chỉ Nhóm A có HLI khác 0.

6.2 Experiment 2: Đánh đổi Pareto của Trigger-Biased Search

Hình 1 cho thấy kết quả trên $N = 60$ scramble ($\lambda \in \{0; 0,5; 1,0\}$, chỉ giai đoạn F2L, ngân sách 40.000 node). Tăng λ từ 0 lên 1,0 nâng độ trùng lặp trigger trung bình từ $0,090 \pm 0,089$ lên $0,255 \pm 0,135$ (tăng $2,8\times$) với chi phí số nước từ $25,7 \rightarrow 27,6$ nước (+7,4%), trong khi thời gian tính trung bình tăng từ 2,77s lên 7,87s. Trên $n = 51$ scramble

Table 1: Nhóm A (AI-CFOP) so với Nhóm B (Kociemba), N=100 scramble, 78 cặp thành công (Wilcoxon $p = 1,65 \times 10^{-14}$, $r = 0,87$ cho khác biệt số nước)

	Nhóm A (AI-CFOP)	Nhóm B (Kociemba)
Số nước TB (sd)	67,2 (11,1)	20,6 (1,1)
Khoảng số nước	47–105	16–22
HLI TB (sd)	0,655 (0,096)	0 (theo định nghĩa)
Tỷ lệ giải thành công	78% (22% timeout)	100%

được giải ở cả $\lambda = 0$ và $\lambda = 1,0$, kiểm định Wilcoxon signed-rank theo cặp xác nhận cả hai khác biệt đều có ý nghĩa thống kê: độ trùng lặp trigger ($W = 29,0$, $p = 8,25 \times 10^{-8}$, $r = 0,83$, effect size rất lớn) và số nước ($W = 209,5$, $p = 0,0014$, $r = 0,60$, effect size lớn). Đáng chú ý, $\lambda = 0,5$ cho thời gian giải *tối đa* quan sát được (55,5s) cao hơn $\lambda = 1,0$ (55,6s, tương đương), và cả hai đều cao hơn nhiều so với mức tối đa của $\lambda = 0$ (16,5s) — nhất quán với chi phí thời gian tính toán phi tuyến, đôi khi nghiêm trọng, của việc thiên vị một heuristic vốn gần-admissible ra khỏi tính admissible (Mục 7).




Figure 1: Độ trùng lặp trigger và số nước đi theo hàm của λ (N=60 scramble). Panel (c) cho thấy đường biên Pareto thực nghiệm.

6.3 Experiment 3: Kiểm định bằng giám khảo con người (kiểu BotPrize)

Theo Hingston [2], chúng tôi thực hiện một nghiên cứu giám khảo con người mù để kiểm tra construct validity của HLI. 24 mẫu (6 mẫu mỗi nhóm từ Nhóm H [lời giải CFOP người thật thật sự, tự thu thập và đã kiểm chứng giải đúng scramble tương ứng], Nhóm A, Nhóm A+ [$\lambda = 1,0$], và Nhóm B) được trình bày dưới dạng chuỗi nước đi thô, không phân đoạn (không có nhãn giai đoạn, để giữ tính mù) cho 28 người chấm biết CFOP, mỗi người chấm điểm mọi mẫu trên thang 1–5 “khả năng đây là lời giải người thật” thông qua một công cụ web

tự xây dựng (kho T ở Mục 4.1 được tái sử dụng cho điểm so sánh trigger-overlap tự động).

Xếp hạng nhóm. Điểm giống-người trung bình theo đúng thứ tự dự đoán: Nhóm H ($3,88 \pm 0,11$) > Nhóm A+ ($3,71 \pm 0,16$) > Nhóm A ($3,42 \pm 0,16$) > Nhóm B ($2,37 \pm 0,19$). Kiểm định Mann-Whitney U so sánh Nhóm B với các nhóm còn lại gộp chung cho thấy tách biệt hoàn toàn về thứ hạng ($U = 0$, $n_1 = 6$, $n_2 = 18$, $p = 1,8 \times 10^{-4}$) — mọi mẫu Nhóm B đều được chấm giống-người thấp hơn mọi mẫu ngoài Nhóm B, xác nhận người chấm nhận diện đáng tin cậy baseline tối-ưu-kiểu-máy-tính là không phải người.

Thiên vị trigger thu hẹp khoảng cách xuống mức không phân biệt được với người. Kiểm định Mann-Whitney theo cặp cho kết quả then chốt: Nhóm A so với Nhóm A+ khác biệt có ý nghĩa ($p = 0,030$), xác nhận người chấm cảm nhận được hiệu ứng của Trigger-Biased Search, không chỉ là chỉ số tự động; nhưng Nhóm H so với Nhóm A+ *không* khác biệt có ý nghĩa ($p = 0,109$), trong khi Nhóm H so với Nhóm A thì có ($p = 0,005$). Nói cách khác, $\lambda = 1,0$ đã đưa các lời giải do AI sinh ra từ trạng thái phân-biệt-được-về-thống-kê-với-người-thật sang trạng thái không-phân-biệt-được-về-thống-kê-với-người-thật trên mẫu này — một “pass” kiểu BotPrize cho điều kiện có thiên vị trigger mà baseline không thiên vị không đạt được.

Construct validity của HLI (RQ-V1). Chúng tôi báo cáo hai phiên bản của tương quan này. Dùng một proxy đơn giản hóa ban đầu theo từng mẫu (Segmentability/Pattern-conformity giả định bằng 1 cho Nhóm A/A+ và bằng 0 cho Nhóm B/H, chỉ dựa trên tư cách thành viên nhóm), tương quan Spearman giữa HLI và điểm đánh giá người trung bình trên toàn bộ 24 mẫu là $\rho = 0,440$ ($p = 0,031$). Tuy nhiên, proxy này đã mô tả sai Nhóm H: vì các lời giải CFOP người thật bị giả định là không có cấu trúc CFOP theo cùng logic dùng cho baseline máy tính, HLI của họ bị đánh giá thấp giả tạo (ví dụ 0,05–0,14) dù nhận điểm đánh giá con người cao nhất. Do đó chúng tôi đã tính lại Segmentability và Pattern-conformity một cách *chính xác*, bằng cách phát lại chuỗi nước đi của mỗi mẫu trên trạng thái xuất phát (đã scramble) thực tế của nó và kiểm chứng, theo đúng thứ tự, các hậu-điều-kiện Cross, F2L, và OLL (Mục 4), và bằng cách kiểm tra xem các trạng thái con OLL/PLL kết quả có khớp với các mục trong bảng thuật toán chuẩn đã kiểm chứng của chúng tôi hay không. Điều này xác nhận Nhóm B có Segmentability= 0 cho cả 6 mẫu (đúng như kỳ vọng — các lời giải gần-tối-ưu của Kociemba đạt Cross, F2L, và OLL/PLL gần như đồng thời trong 1–2 nước cuối, không bao giờ thể hiện cấu trúc trung gian được phân giai đoạn thật sự), trong khi cả 18 mẫu Nhóm A/A+/H đều có Segmentability= 1, với Pattern-conformity dao động có ý nghĩa trong mỗi nhóm (0,5 hoặc 1,0, tùy case con OLL và/hoặc PLL có khớp với bảng của chúng tôi hay không). Với phép tính chính xác này, tương quan *mạnh lên* thành $\rho = 0,487$ ($p = 0,016$) — có ý nghĩa hơn ước lượng proxy, xác nhận

kỳ vọng của chúng tôi rằng proxy nhị phân theo nhóm đã làm loãng thay vì phản ánh đúng construct validity thật sự. Riêng thành phần trigger-overlap vẫn tương quan mạnh nhất với đánh giá con người ($\rho = 0,605$, $p = 0,0017$), cho thấy nó vẫn là thành phần liên quan nhất đến đánh giá con người của HLI trong mẫu này, với Segmentability và Pattern-conformity đóng góp tích cực nhưng yếu hơn.

7 Thảo luận

Trái với trực giác, ban đầu chúng tôi giả thuyết rằng việc làm yếu tính admissible của heuristic thông qua số hạng bonus trigger không-admissible sẽ *làm tăng* tình trạng không hội tụ của tìm kiếm khi λ cao hơn. Dữ liệu cho thấy điều ngược lại: trên cùng $N = 60$ scramble dùng cho Hình 1, tỷ lệ *thất bại* của tìm kiếm (hết ngân sách node ở mọi độ sâu bậc thang) là 15,0% tại $\lambda = 0$, giảm xuống 1,7% tại $\lambda = 0,5$ và 0% tại $\lambda = 1,0$. Một cách giải thích hợp lý là bonus trigger, dù không-admissible, đóng vai trò như một hình thức *định hướng thứ tự tìm kiếm*: các nhánh mở rộng một trigger con người đã biết được khám phá sớm hơn trong hàng đợi ưu tiên (f' thấp hơn), và vì trigger là các chuỗi nước đi ngắn, đã được kiểm nghiệm kỹ, tạo tiến triển cục bộ đáng tin cậy, việc theo chúng có thể giảm hệ số phân nhánh hiệu quả trong thực tế dù bonus không phải là một ước lượng khoảng cách hợp lệ. Điều này không mâu thuẫn với chi phí *thời gian* phi tuyến đã quan sát riêng ở λ cao hơn (Mục 6): tính hội tụ có vẻ đáng tin cậy hơn, nhưng các lần chạy trường-hợp-xấu-nhất cá biệt vẫn có thể mất thời gian lâu hơn đáng kể, tức là thiên vị trigger đánh đổi *độ tin cậy* hội tụ để lấy *phương sai* thời gian tìm kiếm. **[VIỆC CẦN LÀM: Điều tra sau: có thể đây là trùng hợp ngẫu nhiên với $N=60$, nên làm lại với N lớn hơn và nhiều mức lambda hơn (0,25, 0,75...) để xác nhận xu hướng này ổn định, trước khi khẳng định chắc chắn trong bản công bố chính thức.]** Một phân tích hình thức về việc chính xác mất bao nhiêu tính admissible được trình bày dưới đây.

Mất bao nhiêu tính admissible? Heuristic gốc $h(n) = h_{\text{PDB}}(n) + \text{penalty}(n)$ vốn cũng không hoàn toàn admissible (số hạng penalty đã hy sinh đảm bảo cận-dưới hình thức để đổi lấy tính thực tiễn), nên Trigger-Biased Search không tạo ra vi phạm tính admissible *từ đầu* — nó cộng dồn thêm vào một đánh đổi thiết kế có chủ đích đã tồn tại từ trước. Về mặt hình thức, với một đường đi $\text{path}(n)$ có độ dài $g(n)$, $\text{bonus}(\text{path}(n)) \in [0, g(n)]$ (nó có thể bao phủ tối đa mọi nước đi trong đường đi), nên độ đánh giá thấp bổ sung tối đa mà số hạng bonus có thể gây ra bị chặn bởi $\lambda \cdot g(n)$ — tức là độ méo tiềm năng tăng *tuyến tính theo độ sâu đường đi*, không phải theo một hằng số cố định, đây là một kiểu thất bại khác về bản chất (và đáng lo ngại hơn) so với

một heuristic có sai số bị chặn. Điều này giải thích vì sao, khác với tìm kiếm bounded-suboptimal cổ điển (ví dụ weighted A* với hệ số lạm phát cố định và cận suboptimality chứng minh được), chúng tôi hiện chưa cung cấp cận hình thức nào cho tính suboptimal về độ dài lời giải của Trigger-Biased Search; Mục 6 thay vào đó báo cáo điều này bằng thực nghiệm (trung bình +7,4% số nước tại $\lambda = 1, 0$). Một biện pháp giảm nhẹ tự nhiên, để dành cho công việc tương lai, là giới hạn bonus ở một mức tối đa cố định (ví dụ $\min(\text{bonus}(\text{path}(n)), c)$ cho hằng số c nào đó), điều này sẽ khôi phục lại một độ méo bị chặn cố định tương tự như số hạng penalty hiện có.

7.1 Scramble bệnh lý và tình trạng tìm kiếm không hội tụ

Trong Experiment 1, 22% scramble (22/100) không hoàn thành trong ngân sách 20 giây thực ngay cả với ngân sách tìm kiếm đã giảm còn 40.000 node/độ sâu — đáng chú ý, một số thất bại như vậy xảy ra liên tiếp nhau (ví dụ seed 1059–1061 trong lần chạy của chúng tôi), gợi ý bộ sinh scramble random-move có thể tạo ra các chuỗi cấu hình F2L tương tự nhau về cấu trúc, mang tính đối kháng, thay vì độ khó độc lập đồng phân bố (i.i.d.). Một seed cụ thể (1013) bị treo hơn 5 phút ngay cả với ngân sách đã giảm, trước khi chúng tôi đưa vào một timeout thực cứng (dựa trên SIGALRM) trong bộ khai thác đánh giá. Chúng tôi diễn giải điều này là bằng chứng cho thấy heuristic A* có bổ sung penalty theo từng cặp dùng cho F2L (Mục 5) đôi khi bị dẫn vào các vùng tìm kiếm không hiệu quả một cách bệnh lý — một giới hạn về độ tin cậy quan trọng, khác biệt với, nhưng có thể bị khuếch đại bởi, cơ chế thiên vị trigger ở Mục 4. Lưu ý Experiment 1 dùng $\lambda = 0$ xuyên suốt (không áp thiên vị trigger cho giai đoạn F2L); chúng tôi đo riêng mối quan hệ giữa λ và tỷ lệ thất bại hội tụ dùng dữ liệu Experiment 2 (Mục 7), phát hiện — trái với kỳ vọng ban đầu — rằng λ cao hơn liên quan đến *ít hơn*, không phải nhiều hơn, các thất bại hội tụ trên tập dữ liệu đó.

8 Đe dọa đến Tính hợp lệ (Threats to Validity)

- **Tìm kiếm không hội tụ:** như đã báo cáo ở Mục 7.1, 22% scramble trong thiết lập phần cứng/ngân sách đánh giá của chúng tôi không hoàn thành trong timeout 20 giây; kết quả có điều kiện trên 78% đã hoàn thành, có thể không phải là mẫu con đại diện (ví dụ nếu độ khó tương quan với tiềm năng trigger-overlap).
- **Construct validity của HLI:** chỉ số này được thiết kế thủ công,

đã được validate đối chiếu với đánh giá con người thông qua Experiment 3 (Mục 6.3).

- **Thiên vị kho ngữ liệu:** kho finger-trick T được tuyển chọn thủ công (11 trigger), không được suy ra từ log solve người thật; kết quả có thể không tổng quát hóa được cho các solver có vốn trigger khác.
- **Sinh scramble (đã kiểm tra):** chúng tôi đã cài đặt một bộ sinh scramble kiểu WCA random-state (Mục 5) và chạy lại Experiment 1 trên $N = 60$ scramble random-state như một kiểm tra độ mạnh mẽ (robustness check). Kết quả nhất quán với điều kiện random-move (80% so với 78% tỷ lệ giải thành công; số nước trung bình 66,3 so với 67,2; HLI trung bình 0,658 so với 0,655), cho thấy kết quả random-move ban đầu của chúng tôi không phải là hiện tượng giả tạo do scramble dễ hơn một cách có hệ thống. Dù vậy chúng tôi báo cáo minh bạch kết quả từ cả hai bộ sinh (Bảng 1 dùng random-move để nhất quán với Experiment 2; **[VIỆC CẦN LÀM: nếu muốn, đổi Bảng 1 chính sang dùng random-state làm kết quả chính, giữ random-move như robustness check phụ - cả 2 cách đều chấp nhận được, tùy quyết định]**).
- **Khả năng tổng quát hóa đơn-miễn:** kết quả đặc thù cho Rubik's Cube; các tuyên bố về explicability nói chung nên được giới hạn tương ứng.

9 Công việc Tương lai

Tái lập độc lập việc tính lại HLI chính xác. Phép tính Segmentability/Pattern-conformity chính xác trong Mục 6.3 (`research/phase3_survey/recompute_hli_exact.py`) dựa trên một cách hiện thực hóa cụ thể, đã kiểm chứng thủ công của "ranh giới giai đoạn" (chỉ số nước đi đầu tiên mà một hậu-điều-kiện được thỏa mãn, với thứ tự chặt giữa các giai đoạn — xem `docstring` của script để biết lý do cho lựa chọn cụ thể này so với các phương án khác chúng tôi từng thử và loại bỏ ban đầu). Một cài đặt lại độc lập, hoặc validate đối chiếu với ranh giới giai đoạn chuẩn được gán nhãn thủ công cho một tập con mẫu, sẽ củng cố độ tin cậy của thành phần này trong pipeline.

Tái lập quy mô lớn hơn. $N = 24$ mẫu là đủ cho một nghiên cứu pilot nhưng khiêm tốn cho việc ước lượng effect-size chính xác; một nghiên cứu tiếp nối với nhiều mẫu hơn mỗi nhóm (đặc biệt nhiều lời giải Nhóm H hơn từ một nhóm người đóng góp rộng hơn, để giảm phụ thuộc vào thói quen của một solver đơn lẻ) sẽ thu hẹp khoảng tin cậy trên các so sánh nhóm ở Mục 6.3.

Mở rộng pattern-conformity sang Cross/F2L. [VIỆC CẦN LÀM: ý tưởng: xây dựng bảng case F2L 41-case chuẩn (như OLL/PLL đã có), thay thế một phần trigger-overlap bằng pattern-conformity thật sự cho F2L.]

Cơ chế thiên vị thay thế. [VIỆC CẦN LÀM: So sánh trigger-biased A* với cách khác, vd fine-tune trọng số PDB, hoặc học trọng số bonus từ dữ liệu solve người (thay vì λ cố định tay).]

10 Kết luận

Các solver Rubik's Cube hiện có tối ưu hóa cho số nước đi, tạo ra các kế hoạch đúng nhưng không thể diễn giải được đối với người học; các speedcuber con người thay vào đó dùng CFOP, đánh đổi tính tối ưu để lấy cấu trúc và khả năng học được. Chúng tôi đã hình thức hóa sự đánh đổi này bằng ngôn ngữ của lập kế hoạch AI nhận biết con người thành một *Chỉ số Giống-Người* (HLI) đo lường được, và cho thấy bằng thực nghiệm ($N = 100$ scramble) rằng solver AI-CFOP của chúng tôi đạt điểm cao hơn đáng kể trên chỉ số này so với baseline Kociemba tối-ưu-kiểu-máy-tính (HLI trung bình 0,655 so với 0 theo định nghĩa), một khoảng cách robust trên một phạm vi rộng các cách gán trọng số thành phần (Mục 4). Sau đó chúng tôi giới thiệu *Trigger-Biased A* Search*, một cải tiến tối giản, tương thích ngược cho heuristic F2L làm hơn gấp đôi độ trùng lặp trigger với các pattern finger-trick con người (từ 9,0% lên 25,5% tại $\lambda = 1,0$) với chi phí số nước khiêm tốn (+7,4%), trong khi — trái với trực giác — lại *cải thiện* độ tin cậy hội tụ tìm kiếm trên tập kiểm thử của chúng tôi, với cái giá là tăng thời gian tính toán trường-hợp-xấu-nhất. Trong quá trình đó, chúng tôi đã phát hiện và báo cáo minh bạch một hiện tượng tìm kiếm không hội tụ (22% tỷ lệ timeout) tạo thành một giới hạn cụ thể về độ tin cậy của tìm kiếm heuristic có bổ sung penalty trong miền này. Cuối cùng, một nghiên cứu giám khảo con người mù ($N = 24$ mẫu, 28 người chấm, Mục 6.3) đã cung cấp bằng chứng trực tiếp cho construct validity của HLI ($\rho = 0,487$, $p = 0,016$) và, đáng chú ý hơn, cho thấy Trigger-Biased Search đưa các lời giải AI-CFOP từ trạng thái phân-biệt-được-về-thống-kê-với-người-thật ($p = 0,005$) sang trạng thái không-phân-biệt-được-về-thống-kê-với-người-thật ($p = 0,109$) trong đánh giá mù của con người — một minh chứng cụ thể, đã được xác thực bởi con người, rằng việc tối ưu hóa tường minh cho các pattern con người có thể nhận ra, thay vì chỉ số nước đi, thay đổi một cách đo lường được cách người quan sát nhìn nhận các lời giải do AI tạo ra. Chúng tôi hy vọng công trình này khuyến khích thêm sự giao thoa giữa AI tìm kiếm tổ hợp cổ điển và nghiên cứu AI nhận biết con người/AI giải thích được trong các miền câu đố lớn, đã được hiểu rõ như Rubik's

Cube.

References

- [1] T. Chakraborti, A. Kulkarni, S. Sreedharan, D. E. Smith, và S. Kambhampati. Explicability? legibility? predictability? transparency? privacy? security? the emerging landscape of interpretable agent behavior. Trong *Proceedings of the International Conference on Automated Planning and Scheduling (ICAPS)*, 2019.
- [2] P. Hingston. A turing test for computer game bots. *IEEE Transactions on Computational Intelligence and AI in Games*, 1(3):169-186, 2009.
- [3] H. Kociemba. Cube explorer / two-phase algorithm. <http://kociemba.org/cube.htm>, truy cập **VIỆC CẦN LÀM: ngày truy cập**.
- [4] R. E. Korf. Finding optimal solutions to rubik’s cube using pattern databases. Trong *Proceedings of the National Conference on Artificial Intelligence (AAAI)*, 1997.
- [5] A. Kulkarni, Y. Zha, T. Chakraborti, S. G. Vadlamudi, Y. Zhang, và S. Kambhampati. Explicable robot planning as minimizing distance from expected behavior. *arXiv preprint arXiv:1611.05497*, 2016.
- [6] S. McAleer, F. Agostinelli, A. Shmakov, và P. Baldi. Solving the rubik’s cube without human knowledge. *arXiv preprint arXiv:1805.07470*, 2018.
- [7] T. Rokicki, H. Kociemba, M. Davidson, và J. Dethridge. The diameter of the rubik’s cube group is twenty. *SIAM Review*, 56(4):645-670, 2014.
- [8] M. Świechowski và D. Ślęzak. The many challenges of human-like agents in virtual game environments. Trong *Proceedings of the 24th International Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, trang 1996-2004. IFAAMAS, 2025. Cũng có trên arXiv preprint arXiv:2505.20011.
- [9] K. Lakkaraju, T. Hassan, V. Khandelwal, P. Singh, C. Bradley, R. Shah, và cộng sự, và D. Wu. Allure: A multi-modal guided environment for helping children learn to solve a rubik’s cube with automatic solving and interactive explanations. Trong *Proceedings of the AAAI Conference on Artificial Intelligence*, tập 36, trang 13185-13187, 2022.

- [10] K. Vanacore, J. Ocumpaugh, F. Agostinelli, D. Wu, S. Vuruma, và M. Irvin. Student engagement in ai-assisted complex problem solving: A pilot study of human-ai rubik’s cube collaboration. *arXiv preprint arXiv:2511.01683*, 2025. Ghi chú: bản thảo chưa công bố, bài báo đang chuẩn bị nộp tại thời điểm viết bài – kiểm tra lại tình trạng công bố trước khi trích dẫn như một nguồn đã bình duyệt.